

Laboratorio Práctico 04: Pandas I - Extracción, Exploración y Transformación (ETL)

Curso: Python para Análisis de Datos (ETL)

Instructor: Christian Condori

Alumno(a): _____

Fecha: _____ **Nota:** _____

Instrucciones Generales

- Desarrolle las soluciones de este laboratorio directamente en celdas de código en su entorno de **Google Colab**.
- Asegúrese de importar las librerías necesarias (pandas y numpy) en la primera celda de su cuaderno.
- Comente su código explicando la lógica detrás de cada paso.
- Para visualizar las tablas resultantes, utilice la función `display(df)` en lugar de `print()`.

Caso de Negocio: Limpieza del Reporte Regional de Ventas

Usted trabaja como Data Engineer para una cadena de tiendas Retail. El gerente regional le acaba de enviar el reporte de ventas del último trimestre. Sin embargo, el archivo fue exportado desde un sistema muy antiguo (Legacy System): tiene filas de "basura" al inicio, columnas con formatos incorrectos y valores nulos.

Su misión es realizar la Fase **EXTRACT** (leer el archivo correctamente) y la Fase **TRANSFORM** (limpiar y estandarizar la data) para finalmente generar un reporte agrupado.

Parte 1: Extracción Inteligente (Fase EXTRACT)

Para simular el archivo defectuoso del sistema, primero copie y ejecute el siguiente código en su Colab para generar el archivo de prueba localmente:

Python

```
# EJECUTE ESTA CELDA PARA CREAR EL ARCHIVO DE PRUEBA
datos_sucios = """Reporte Confidencial de Ventas
Generado automaticamente por el sistema Legacy
id_transaccion;fecha_venta;cliente;ciudad;monto_usd
1001;2026-04-15; Ana Gomez ;lima;250.50
1002;2026-04-18;carlos ruiz;cusco;Error_Red
1003;2026/05/02; LUIS PEREZ;arequipa;1200.00
1003;2026/05/02; LUIS PEREZ;arequipa;1200.00
```

```
1004;2026-05-10;Maria Diaz;LIMA;No_Data
1005;2026-06-20;Jorge Soto;cusco;85.90" " "
```

```
with open("ventas_legacy.csv", "w") as f:
    f.write(datos_sucios)
```

Misiones:

1. Utilice la función `pd.read_csv()` para leer el archivo "ventas_legacy.csv".
2. Configure los parámetros adecuados para que Pandas entienda que el archivo está **separado por punto y coma (;)** y que debe **ignorar las 2 primeras filas** de basura.
3. Guarde el resultado en un DataFrame llamado `df_ventas` y muéstrelo en pantalla.

Parte 2: Exploración y Diagnóstico (Data Profiling)

Antes de limpiar, debemos conocer el estado de salud de nuestro DataFrame.

Misiones:

1. Utilice el método adecuado para imprimir un **resumen técnico** del DataFrame (cantidad de columnas, tipos de datos actuales y memoria usada). *Pista: Recuerde qué tipo de dato asume Pandas cuando hay texto mezclado con números.*
2. Imprima por pantalla la cantidad exacta de **filas y columnas** usando el atributo `.shape`.
3. Utilice el método `.isnull().sum()` para verificar si Pandas detectó algún valor nulo (NaN) de forma automática.

Parte 3: El Arte del Casteo y Limpieza (Fase TRANSFORM)

Como notó en el paso anterior, Pandas clasificó la fecha y el monto como texto (object). Debemos transformar el "ADN" de esos datos.

Misiones:

1. **Casteo de Fechas:** Convierta la columna `fecha_venta` al tipo `Datetime` utilizando `pd.to_datetime()`. Asegúrese de incluir el parámetro `errors='coerce'` para proteger el código.
2. **Casteo Numérico:** Convierta la columna `monto_usd` a número utilizando `pd.to_numeric(..., errors='coerce')`.
3. **Manejo de Nulos:** Al castear el monto, los textos "Error_Red" y "No_Data" se habrán convertido en NaN. Utilice el método `.fillna()` para rellenar esos vacíos con el valor 0.
4. **Eliminación de Duplicados:** Aplique el método `.drop_duplicates(inplace=True)` para eliminar cualquier transacción que se haya registrado dos veces por error.

Parte 4: Reglas de Negocio y Manipulación de Textos

Ahora que los datos matemáticos están sanos, vamos a estandarizar los textos y crear nuevas

variables.

Misiones:

1. Limpie la columna cliente eliminando los espacios en blanco a los extremos y convirtiendo todos los nombres a formato **Título** (ej. "Ana Gomez"). *Pista: Utilice .str.strip() y .str.title().*
2. Estandarice la columna ciudad convirtiendo todo el texto a **MAYÚSCULAS**.
3. **Lógica Condicional:** Importe la librería numpy. Cree una nueva columna llamada tipo_cliente utilizando np.where(). La regla es:
 - Si el monto_usd es estrictamente mayor a 500, el cliente es "VIP".
 - De lo contrario, el cliente es "Regular".

Parte 5: Agregación y Reporte Final

Para finalizar el proceso ETL, prepararemos un resumen gerencial.

Misiones:

1. Extraiga el mes de la venta utilizando el accesor de fechas (.dt.month) y guárdelo en una nueva columna llamada mes_operacion.
2. Utilice el método .groupby() para agrupar las ventas por mes_operacion y sume (.sum()) la columna monto_usd. Guarde este resumen en la variable reporte_mensual.
3. Muestre en pantalla el reporte_mensual resultante utilizando display().