

Laboratorio Práctico 05: Pandas II - Limpieza Avanzada, Merge y Exportación

Curso:	Python para Análisis de Datos (ETL)	Instructor:	Christian Condori
Alumno(a):		Fecha:	

Instrucciones Generales

- Desarrolle las soluciones en celdas de código independientes dentro de su entorno de **Google Colab**.
- Documente y comente su código explicando la lógica aplicada. Es vital mantener las buenas prácticas enseñadas en clase.
- Utilice la función `display()` para mostrar las tablas resultantes de sus transformaciones.

Caso de Negocio: Consolidación de Planilla y Evaluación de Desempeño

El departamento de Recursos Humanos le ha enviado dos fuentes de datos distintas: un reporte con los datos base de los empleados (con errores de tipeo y formatos incorrectos) y un reporte con las evaluaciones de desempeño del último semestre. Su objetivo como Ingeniero de Datos es limpiar la información, cruzar ambos reportes, calcular los bonos correspondientes mediante lógicas avanzadas y exportar el archivo definitivo listo para que Finanzas realice los pagos.

Parte 1: Creación de los Datos y Limpieza Avanzada

Cópielo y ejecute el siguiente código para cargar los DataFrames base en la memoria de su entorno de Google Colab:

```

import pandas as pd
import numpy as np

# Tabla 1: Base de Empleados (Con errores intencionales)
df_empleados = pd.DataFrame({
    "id_emp": ["E001", " E002 ", "e003", "E004"],
    "nombre_completo": [" ana perez", "LUIS GOMEZ", "carlos ruiz", "maria diaz "],
    "salario_base": ["USD 1200", "USD 1500", "USD 900", "USD 2000"]
})

# Tabla 2: Evaluaciones de Desempeño
df_evaluaciones = pd.DataFrame({
    "id_empleado": ["E001", "E002", "E003", "E009"], # Nota: E009 no existe en la base principal
    "calificacion": ["A", "B", "A", "C"]
})

```

Misiones:

1. Limpie la columna `id_emp` del `df_empleados`. Utilice `.apply(lambda x: ...)` o los métodos encadenados de `.str` para eliminar los espacios en blanco a los extremos y convertir todas las letras a mayúsculas.
2. Estandarice la columna `nombre_completo` para que no tenga espacios sueltos a los lados y utilice el formato de Título (Ej. "Ana Perez").
3. Limpie la columna `salario_base` utilizando `.apply()` y una función `lambda` para quitar el texto "USD " y convertir el valor resultante a un número decimal (`float`).

Parte 2: Cruce de Tablas (Merge)

Ahora debe unir la información de desempeño a la base principal de empleados.

Misiones:

1. Utilice `pd.merge()` para realizar un cruce tipo **LEFT JOIN** donde `df_empleados` sea la tabla "mandante" (a la izquierda). Queremos mantener a todos los empleados de la base, tengan o no evaluación.
2. Dado que las llaves se llaman distinto (`id_emp` en la primera tabla vs `id_empleado` en la segunda), utilice los parámetros `left_on` y `right_on`.
3. Guarde la tabla cruzada resultante en una variable llamada `df_consolidado`.

4. Notará que el cruce generó columnas redundantes. Elimine la columna `id_empleado` que provino de la tabla de la derecha utilizando `.drop(..., axis=1)`.

Parte 3: Lógica Condicional Multivariable (.apply con def)

Finanzas ha determinado la siguiente regla para asignar los bonos de desempeño a la planilla cruzada.

Misiones:

1. Cree una función en Python (utilizando `def`) llamada `calcular_bono(fila)` que reciba una fila completa de la tabla.
2. La lógica interna de la función debe ser:
 - Si la calificación es "A", el bono será equivalente al **20%** del `salario_base`.
 - Si la calificación es "B", el bono será equivalente al **10%** del `salario_base`.
 - Si la calificación es nula o cualquier otra letra, el bono será **0**.
3. Aplique su función al `df_consolidado` utilizando el método `.apply(..., axis=1)` para crear una nueva columna llamada `bono_asignado`. (Recuerde que `axis=1` es vital para que la función pueda leer múltiples columnas de la misma fila).
4. Cree una columna final llamada `salario_neto` que sume el salario base más el bono asignado.

Parte 4: Fase LOAD (Exportaciones al Sistema)

El pipeline ETL no termina hasta que los datos no son cargados a su destino final.

Misiones:

1. Exporte el DataFrame final `df_consolidado` a un archivo plano llamado `"planilla_final_2026.csv"`.
2. Asegúrese de incluir el parámetro `index=False` para que el sistema financiero no reciba una columna extra de números de índice sin sentido.
3. (Reto Adicional) Exporte el mismo DataFrame a un archivo de Excel (`.xlsx`) en una pestaña que se llame `"Planilla_Neta"`.

Entregable

Al finalizar, verifique en el panel de "Archivos" de Google Colab que sus documentos CSV y Excel se hayan generado correctamente con los datos limpios. Descargue su Notebook en formato .ipynb y súbalo a la plataforma virtual.